

身体動作の個人差に対してロバストな特徴量空間評価関数の提案

森雅也[†] 秋月拓磨^{††} 高橋弘毅^{†††} 大前佑斗[†]

[†] 東京工業高等専門学校 電気工学科

東京都八王子市梶田町 1220-2

^{††} 豊橋技術科学大学

愛知県豊橋市天伯町雲雀ヶ丘 1-1

^{†††} 長岡技術科学大学大学院 工学研究科 情報・経営システム工学専攻

新潟県長岡市上富岡町 1603-1

あらまし 近年、慣性センサと機械学習を併用した身体動作の自動判定が盛んに行われている。一般に、身体動作には個人差があり、同じ動作でも被験者毎に得られるデータは異なる。以上より、精度の高い判定器を構築するためには、潜在的な判別誤差が生じにくく、個人差が空間上に表れにくい特徴量空間を選出するための指標が必要である。そのため本研究では、これらを重視する特徴量空間の評価関数を提案する。提案手法は、個別の被験者毎の身体動作に対して、それらの発生する確率を正規分布とカーネル分布から構成し、それらを活用して判別誤差の発生頻度を評価する。そして被験者全員の評価の平均と標準偏差を計算し、それらが最小と評価された特徴量空間を最適とみなす手法である。本研究は、身体動作判定を異常値検知問題へと帰着させた場合での適用を想定したものである。

キーワード 機械学習, 特徴量空間, 数理最適化, 身体動作判定, 異常値検知問題

On Evaluation Function for Feature Space Considered Robustness to Individual Difference of Human Activities

Masaya MORI[†], Takuma AKIDUKI^{††}, Hirotaka TAKAHASHI^{†††}, and Yuto OMAE[†]

[†] Department of Electrical Engineering, National Institute of Technology, Tokyo College

1220-2, Kunugida, Hachioji, Tokyo, 193-0942

^{††} Toyohashi University of Technology

1-1, Hibarigaoka, Tenpakucho, Toyohashi, Aichi, 441-8580 Japan

^{†††} Department of Information and Management Systems Engineering, Nagaoka University of Technology

1603-1, Kamitomioka, Nagaoka, Niigata, 940-2188 Japan

Abstract Recently, various human activity recognitions by using inertial measurement units and machine learning are investigated. In general, even if the subjects carry out same activity, the data from sensors are different behavior by the individual difference. To develop a classifier model of the higher quality, the index for the feature space to suppress the classification error and individual difference is required. Therefore, we propose an evaluation function for the feature space considered the robustness to the individual difference of the human activities. In our method, we calculate the probability distributions (Gauss distribution and Kernel distribution) to occur the human activities for each subject. By using these probability distributions, we evaluate the possibility for the classification error. After that, the mean and standard deviation for the evaluation of all subjects are calculated, and we regard the evaluated minimum value as the optimal feature space. This proposed method supposes the application of the human activity recognition to anomaly detection problem.

Key words machine learning, feature space, mathematical optimization, human activity recognition, anomaly detection problem

1. はじめに

近年、人を対象にした加速度データと機械学習を併用した身体動作の自動判定が盛んに行われている (例えば [1] [2] など). しかしながら, 身体動作は個人差があり, 例えば, 歩行動作に着目してみても, 足の長さや, 体重, けがなどの要因で個人差を原因として同じ動作でも得られる加速度データは異なる. そのため, 機械学習により身体動作の自動判定を行おうとした場合には, 多くの人に対して重要な特徴量を探索, または構築しなければならないことが指摘されている [3]. その実現のためには, 多くの人に対して良いといえるような特徴量空間を良いと判断できる特徴量空間の評価関数が必要である. しかし, 既存の特徴量空間の評価関数は, 個人差が考慮されていない. 以上より本研究では, 特定個人のみならず多くの人に対して良いといえるような特徴量空間を良いと判断するような評価関数を考案する.

機械学習における身体動作判定は, 大きく分けて異常値検知問題とクラス分類問題に分けられる. 例として, 自動車運転時の危険な動作による事故の削減を目的とした身体動作判定において提案する評価関数の解説を行う. 図 1 の (a), (b), (c) はそれぞれの特徴量空間における各運転動作のプロットを表しており, 凡例は各プロットの運転動作が示されている. 図 1 の (a) は, 正常な運転におけるプロットとそれ以外の危険な運転動作におけるプロットの 2 つを分類した特徴量空間である. 図 1 の (b) は, 正常な運転, 片手運転, わき見運転, スマートフォンの利用, その他さまざまな異常運転のプロットがそれぞれクラス毎に分類されている特徴量空間である. 図 1 の (c) は, 各運転動作のプロットが混合しており, 識別境界を引くのが難しい特徴量空間である. 異常値検知問題は, 正常か異常かを識別する問題であるので, 図 1 の (a) をみたとような特徴量空間の探索が必要であり, クラス分類問題は, 各プロットをそれぞれクラス毎に分類する問題であるので, 図 1 の (b) をみたとような特徴量空間の探索が必要である.

クラス分類問題は, 識別する動作が決まっている場合には利便性が高いが, 例のように異常な動作が無数にあり, 識別する動作が決まっていない場合は, 検出したい動作すべてにラベルを与え, 教師データを取得することは困難である (多田らも類似の主張をしている [4]). また, 図 1 の (a) のような異常値検知問題に優れた空間を発見するより, 図 1 の (b) のようなクラス分類問題に優れた空間を発見することは, 相対的に困難である. 実際の適用時を考えると, 運転中の危険な動作可否を判断できればよいので, 異常動作内のさまざまな動作をクラス分類する必要性は低い. したがって本研究は, 想定した例のような異常値検知問題の身体動作判定を対象とした特徴量空間の評価関数を提案する.

2. 理 論

2.1 概 要

本稿では, $\langle x \rangle$ を特徴量 x により構成される特徴量空間を表現する記法とする. 例えば, 図 2 の特徴量空間は $\langle x_n, x_m \rangle$ で

表現される. はじめに, 本稿で提案する理論が対象とする課題について説明する. このため, 以下の集合を定義する:

$$x_n, x_m \in X := \{x_1, x_2, \dots, x_{F_{\max}}\}, \quad (1)$$

$$i \in I := \{1, 2, \dots, N_{\text{sub}}\}, \quad (2)$$

$$c \in C := \{\text{ano}, \text{nor}\}. \quad (3)$$

ここで, X は特徴量を要素とする集合であり, そのサイズは F_{\max} である. I は被験者を要素とする集合であり, そのサイズは N_{sub} である. つまり, N_{sub} 人分のデータセットを取得していることを前提とする. ここでいうデータセットとは, 個別の被験者から多数の正常データと少数の異常データによって構成されているものを指す. C はクラスを要素とする集合であり, 異常 (ano) と正常 (nor) によって構成される. 以上の定義のもと, 本研究で扱う課題は, 特徴量集合 X から N_{sub} 人に対して異常と正常の判定に有効な特徴量 $\langle x^{\text{opt1}}, \dots, x^{\text{optu}} \rangle$ を探索し, 発見することをである. 今回は, $u = 2$ とする.

提案手法では, 最適な特徴量空間を探索するため, $x_n, x_m \in X$ により構成される特徴量空間 $\langle x_n, x_m \rangle$ ($n, m = 1, \dots, F_{\max}, n \neq m$) がどの程度異常値検知問題において優れているのか, 被験者ごとに指標を計算する. さらに, 全被験者の指標が均一に優れている特徴量空間を, 最適な特徴量空間 $\langle x^{\text{opt1}}, x^{\text{opt2}} \rangle$ ($x^{\text{opt1}}, x^{\text{opt2}} \in X$) として採用する.

本研究で提案する特徴量空間の評価指標の概略を図 2 に示す. 提案手法は, (1) F_{\max} 個の特徴量より任意の 2 つの特徴量で記述される特徴量空間 $\langle x_n, x_m \rangle$ ($n, m = 1, \dots, F_{\max}, n \neq m$) 上において, 被験者 i の正常データと異常データを生起させる確率密度関数を構成するフェーズ, (2) 被験者 i の確率密度関数を利用して誤分類の起こしやすさを 1 次元の実数値に加工するフェーズ, (3) N_{sub} 人の結果を指標値に要約するフェーズの 3 つにより構成される. (1) のフェーズは, 図 2 の左側に該当し, 2.2-2.3 節で言及する. (2) のフェーズは, 図 2 の右側に該当し, 2.4-2.5 節で言及する. (3) のフェーズは, 2.6 節で言及する.

はじめに, 正常データを生起させる確率密度関数と異常データを生起させる確率密度関数を構築する. 特に, 正常データを生起させる確率密度関数の構築は 2.2 節, 異常データを生起させる確率密度関数の構築は 2.3 節で言及する.

2.2 正常データの確率密度関数

正常データは, 規定された動作のみのデータなので, 図 2 の左上で示したように, プロットが一カ所に集中すると想定される. したがって, 今回は確率密度関数の形状として, 多変量正規分布を採用した.

ある被験者 i における特徴量 x_n, x_m の正常データの平均値を $\overline{x_n}, \overline{x_m}$ とし, 平均ベクトルを $\boldsymbol{\mu}^i(x_n, x_m) = (\overline{x_n}, \overline{x_m})^T$ と定義する. また, 被験者 i における特徴量 x_n, x_m の正常データの分散共分散行列を $V^i(x_n, x_m)$ とし, $\mathbf{x} = (x_n, x_m)^T$ と定義すると, 被験者 i の特徴量空間上の正常データは以下の確率分布に従い発生すると仮定をおく:

$$P_{c=\text{nor}}^i(x_n, x_m) = \frac{1}{2\pi\sqrt{|V^i(x_n, x_m)|}} \exp \left\{ -\frac{1}{2} \times (\mathbf{x} - \boldsymbol{\mu}^i(x_n, x_m))^T V^i(x_n, x_m)^{-1} (\mathbf{x} - \boldsymbol{\mu}^i(x_n, x_m)) \right\}. \quad (4)$$




図1 異常値検知問題とクラス分類問題における優れた特徴量空間の差異

この確率分布から、被験者 i における特徴量 x_n, x_m の正常データが生じやすい座標を特定することが可能となる。

2.3 異常データの確率密度関数

異常データとは、規定された動作から逸脱したデータなので、図2の左下で示したように、プロットが一か所に集まらなないと想定される。したがって、今回は確率密度関数の形状として、多変量カーネル分布を採用した。

ある被験者 i における特徴量 x_n, x_m の異常データの数 N^i とし、被験者 i の特徴量 x_n, x_m におけるバンド幅を h_n^i, h_m^i と定義する（バンド幅はSilvermanのルールを適用する）。また、被験者 i の特徴量 x_z における l 個目の異常データを $x_{(z)l}^i$ とし、カーネル関数をガウス関数 $K(a) = \frac{1}{\sqrt{2\pi}} \exp\{-\frac{1}{2}a^2\}$ で定義すると、被験者 i の特徴量空間上の異常データは以下のカーネル分布に従い発生する：

$$P_{c=\text{ano}}^i(x_n, x_m) = \frac{1}{N^i} \sum_{l=1}^{N^i} \prod_{z \in \{n, m\}} \frac{1}{h_z^i} K\left(\frac{x_z - x_{(z)l}^i}{h_z^i}\right). \quad (5)$$

この確率分布から、被験者 i における特徴量 x_n, x_m の異常データが生じやすい座標を特定することが可能となる。

2.4 重複関数の構成

本節では、正常データの確率分布と異常データの確率分布を利用して、特徴量空間の評価指標を導入する。これは、2.1節で示した(2)のフェーズに相当する。被験者 i の特徴量空間 $\langle x_n, x_m \rangle$ において、正常データの確率分布と異常データの確率分布を比較し、各データが生じやすい座標同士が重なっているほど、誤分類を起こしやすい特徴量空間であると考えられる。特徴量空間の各座標において、誤分類の起こしやすさを表現するため、以下の関数を考える：

$$D^i(x_n, x_m) = \prod_{c \in C} P_c^i(x_n, x_m). \quad (6)$$

$P_c^i(x_n, x_m)$ はいずれも確率密度関数であるため、定義域全体で正の値を取る。したがって、それらの乗算により得られる関数 $D^i(x_n, x_m)$ もまた、定義域全体で正の値を取ることが保証される。そして、 $D^i(x_n, x_m)$ は、正常データと異常データの生じ確率が高い座標同士が重なっている場合、高い値を取る性質を

持つ。そのため、 $D^i(x_n, x_m)$ を重複関数と呼ぶことにする。

2.5 誤分類危険度

被験者 i における特徴量 x_n, x_m の重複関数 $D^i(x_n, x_m)$ を定義域全体で積分した関数：

$$I^i(x_n, x_m) = \int_0^1 \int_0^1 D^i(x_n, x_m) dx_n dx_m, \quad (7)$$

を、被験者 i における特徴量 x_n, x_m の誤分類危険度と定義する。誤分類危険度 $I^i(x_n, x_m)$ は、重複関数 $D^i(x_n, x_m)$ の体積に相当する1次元の実数値関数であり、正常、異常データの生じ確率が高い座標同士が重なっている領域が多いほど、高い値を取る性質を持つ。そのため、誤分類危険度が最も小さい特徴量空間が被験者 i にとって最も重要な特徴量空間であることを意味している。

2.6 最適化問題の定式化

本節では、全被験者の誤分類危険度を利用して、全被験者の指標が均一に優れている特徴量空間 $\langle x^{\text{opt1}}, x^{\text{opt2}} \rangle$ を探索するための最適化問題を考える。全被験者の指標が均一に優れている特徴量空間 $\langle x^{\text{opt1}}, x^{\text{opt2}} \rangle$ とは、全被験者の誤分類危険度の平均が小さい特徴量空間のことある。また、一部の被験者の誤分類危険度が極端に低いため、全体の誤分類危険度が高いにもかかわらず最も優れている特徴量空間と判断されないために、各被験者の誤分類危険度のばらつきが小さい必要がある。よって、以下の最適化問題を解くことにより、 $x^{\text{opt1}}, x^{\text{opt2}}$ を得ることができる：

$$\langle x^{\text{opt1}}, x^{\text{opt2}} \rangle = \arg \min_{x_n, x_m} \left[\alpha \text{mean}\{I(x_n, x_m)\}' + \beta \text{std}\{I(x_n, x_m)\}' \right]. \quad (8)$$

$\text{mean}\{I(x_n, x_m)\}'$ は、特徴量空間 $\langle x_n, x_m \rangle$ における全被験者の誤分類危険度の平均 $\text{mean}\{I(x_n, x_m)\}$ を規格化したものを表現しており、 $\text{std}\{I(x_n, x_m)\}'$ は、特徴量空間 $\langle x_n, x_m \rangle$ における全被験者の誤分類危険度の標準偏差 $\text{std}\{I(x_n, x_m)\}$ を規格化したものを表現している。この規格化は：

$$v\{I(x_n, x_m)\}' = \frac{v\{I(x_n, x_m)\} - \min(v\{I(x_n, x_m)\})}{\max[v\{I(x_n, x_m)\}] - \min[v\{I(x_n, x_m)\}]}, \quad (9)$$

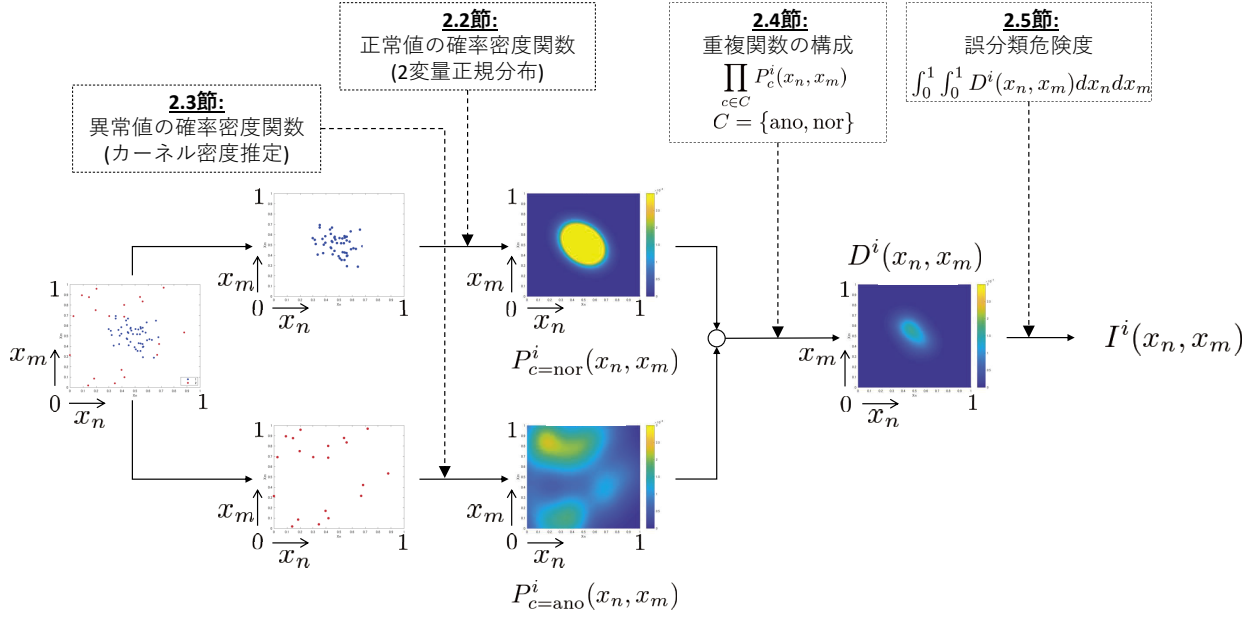


図2 被験者 i の特徴量空間 $\langle x_n, x_m \rangle$ における誤分類危険度 (異常値検知)

によって行い、ここで、 v は mean または std を示す。平均と標準偏差では値のスケールが異なるので、規格化する事により平均と標準偏差の値のスケールを均一にする必要がある。また、 α と β は規格化された平均と標準偏差の重みを表しており、各項の重みは、 $\alpha + \beta = 1$ を満たすことと定義される。つまり、式 (8) は特徴量空間 $\langle x_n, x_m \rangle$ における全被験者の誤分類危険度の平均に重み α を掛けた値と、特徴量空間 $\langle x_n, x_m \rangle$ における全被験者の誤分類危険度の標準偏差に重み β を掛けた値を足し合わせた値が一番小さくなる特徴量空間を最も最適な特徴量空間 $\langle x^{\text{opt1}}, x^{\text{opt2}} \rangle$ にするという意味している。

3. 評価実験

本章では、本研究で提案した特徴量空間の評価指標が、既存手法よりも優れた特徴量を選出できるのか否かを検証する。検証方法として、はじめに、5 名分の被験者から得られたことを想定したダミーデータ 14 種の特徴量空間を用意した。また、個別の被験者毎の正常と異常データの混合度合いが異なる 2 次元特徴量空間プロットを 4 パターン (Very Good, Good, Bad, Very Bad) 用意した。正常データはいずれのパターンでも、以下のパラメータに従う正規分布によって 50 プロット用意した:

$$u = (0.5 \ 0.5)^T, \quad s = \begin{pmatrix} 0.1^2 & 0 \\ 0 & 0.1^2 \end{pmatrix}. \quad (10)$$

u は正常データの平均ベクトルであり、 s は正常データの分散共分散行列である。異常データは一樣乱数に従って 20 プロット用意した。Very Good は、正常データを生じさせる正規分布のパラメータである平均と標準偏差から、平均 ± 1 標準偏差の領域に異常データが存在しないという条件を満たす特徴量空間である。すなわち、正常データと異常データが明瞭に分かれている理想的な空間である。Good は、平均 ± 1 標準偏差の領域に異常データが 5 プロット存在するという条件を満たす特徴量空間である。

Bad は、平均 ± 1 標準偏差の領域に異常データが 10 プロット存在するという条件を満たす特徴量空間である。Very Bad は、平均 ± 1 標準偏差の領域に異常データが 15 プロット存在するという条件を満たす特徴量空間である。すなわち、正常データと異常データを判別することが困難な空間である。5 名分の被験者から得られたデータ (Very Good から Very Bad) が 14 種の特徴量空間に割り当てられたと想定した内容が表 1 の 2 列目から 6 列目までである。本研究では、多くの被験者の正常データと異常データを明瞭に判別できる空間をロバストな特徴量空間だと考えている。例えば、Very Good や Good が集中する case1, case2, case5 などである。また、case8 (Very Bad が 3 人, Very Good が 2 人) は少数の被験者に対して極めて有効な特徴量空間であり、それに対し、case11 (Good が 3 人, Bad が 2 人) は多くの人に対して有効な特徴量空間といえる。本研究では、全員に対してロバストな特徴量空間を考えているので、case11 を重視したい。

以上の事柄が適切に反映されているか検証するために、提案手法を 14 種の特徴量空間に適用した。さらに、提案手法が既存手法よりどれだけ優れているかを検証するために、クラス内分散・クラス間分散比 [5] と Minimum Reference Set (以下、MRS と記す) [6] の 2 つを使用した。クラス内分散・クラス間分散比はクラス間の距離が離れており、かつ、各クラスの分散が小さい特徴量空間を良いと評価する手法である。MRS は、少ない教師データで全教師データを分類できる特徴量空間を良いと評価する手法である。

提案手法により得られた結果を 7 列目から 8 列目に示す。また、1 から 14 までの数字は、各手法による 14 種の特徴量空間の順位を表している。

$(\alpha, \beta) = (0.5, 0.5)$ の条件で、提案手法をダミーデータに対して適用した。 α は全被験者の誤分類危険度の平均に対する重

表 1 各手法の特徴量空間に対する評価結果

Feature Space	subjects					提案手法	提案手法	クラス内分散	MRS
	1	2	3	4	5	$(\alpha, \beta) = (0.5, 0.5)$	$(\alpha, \beta) = (0.7, 0.3)$	クラス間分散比	
case1	Very Good	Very Good	Very Good	Very Good	Very Good	1	1	3	1
case2	Good	Good	Good	Good	Good	2	3	11	6
case3	Bad	Bad	Bad	Bad	Bad	6	7	8	14
case4	Very Bad	Very Bad	Very Bad	Very Bad	Very Bad	9	12	12	7
case5	Very Good	Very Good	Very Good	Good	Good	3	2	9	2
case6	Very Good	Very Good	Very Good	Bad	Bad	7	4	2	4
case7	Very Good	Very Good	Very Good	Very Bad	Very Bad	12	10	10	5
case8	Very Bad	Very Bad	Very Bad	Very Good	Very Good	13	11	14	13
case9	Very Bad	Very Bad	Very Bad	Good	Good	14	14	1	11
case10	Very Bad	Very Bad	Very Bad	Bad	Bad	11	13	7	9
case11	Good	Good	Good	Bad	Bad	4	5	13	3
case12	Bad	Bad	Bad	Good	Good	5	6	6	10
case13	Very Good	Good	Bad	Very Bad	Good	10	9	5	8
case14	Very Good	Good	Bad	Very Bad	Bad	8	8	4	12

みを表しており、 β は各被験者の誤分類危険度のばらつきに対する重みを表している。はじめは、提案手法の基本的な傾向を確認するため、 $(\alpha, \beta) = (0.5, 0.5)$ とした。その結果、1 位は case1, 2 位は case2, 3 位は case5 となった。case1 は、すべてが Very Good であり、最適として用意した特徴量空間である。これを 1 位と評価していたので、望ましい結果が得られたと解釈できる。一方で、Very Good が 3 つと Good が 2 つの case5 が 3 位、すべてが Good であった case2 が 2 位と評価されている。case5 は case2 より上位になるほうが望ましいが、結果は逆になってしまった。評価関数の構造を考えると、case5 は case2 より全被験者の平均は良いと判断されるが、ばらつきは悪いと判断される。結果として、ばらつきの大きさが重要視されすぎてしまったため、case2 は case5 より上位になったのだと考えられる。同様の問題が、case4 と case7, case4 と case8 の順序関係でも確認された。

この問題の解決策として、 α を大きくし、 β を小さくすることが挙げられる。それゆえ、 $(\alpha, \beta) = (0.7, 0.3)$ として再度提案手法を適用した。その結果、上記で挙げた 3 パターンの順序関係の問題が解決された。また、全体的な順序関係も概ね望ましい結果が得られた。したがって、誤分類危険度のばらつきより、平均をやや重要視したほうが望ましい結果が得られると考えられる。

既存手法として、クラス内分散・クラス間分散比を適用した。その結果を 9 列目に示す。1 位は case9, 2 位は case6, 3 位は case1 となっており、全体的に適切に評価をすることができなかった。これは、クラス分類問題に適した手法であり、今回の異常値検知問題には適切に機能しなかったためだと考えられる。別の既存手法として、MRS を適用した。その結果を 10 列目に示す。1 位は case1, 2 位は case5, 3 位は case11 となっており、1 位、2 位の順序関係は良好な結果が得られたが、3 位から下の順序関係は望ましくない結果となった。例として、全員にロバストな case2 よりもロバストでない case6, case7 が上位にきてしまっていることが挙げられる。

以上の結果より、本数値実験においては、提案手法が異常値検知問題において、身体動作判定に対するロバストな特徴量空間を探索できる手法である可能性を確認できた。

4. 終わりに

本研究では、異常値検知問題を対象とした個人差に対してロバストな特徴量空間を探索するために、多くの人に対してなロバストな空間を最適だと評価する手法を提案した。提案手法は、はじめに各被験者の身体動作のデータから、正規分布とカーネル分布を適用し、式 (6) で定義した重複関数を得る。その後、重複関数を多重積分し、誤分類危険度を個別に導き出す。得られた被験者全員の誤分類危険度を式 (8) に適用し、特徴量空間のロバスト性を計る。その結果、ダミーデータでの全員の特徴量空間に対するロバスト性を評価することができた。ダミーデータでの評価は望ましい結果が得られたので、今後は実際に取得したデータでの有効性を確かめたい。

謝辞 本研究は JSPS 科研費 17K13179 (研究代表者: 大前佑斗), 16K06156 (研究代表者: 秋月拓磨), および, 17K05437 (研究代表者: 高橋弘毅) の助成を受けたものである。

文 献

- [1] Khan, A. M., Lee, Y. K., Kim, T. S., “A Tri-axial Accelerometer-Based Physical-Activity Recognition via Augmented-Signal Features and a Hierarchical Recognizer”, *IEEE transactions on information technology in biomedicine*, 14(5), pp.1166-1172, 2010.
- [2] Omae, Y., Kon, Y., Kobayashi, M., Sakai, K., Shionoya, A., Takahashi, H., Akiduki, T., Nakai, K., Ezaki, N., Sakurai, Y., Miyaji, C., “Swimming Style Classification Based on Ensemble Learning and Adaptive Feature Value by Using Inertial Measurement Unit”, *Journal of Advanced Computational Intelligence and Intelligent Informatics*, 21(4), pp.616-631, 2017.
- [3] Omae, Y., Takahashi, H., “Feature Selection Algorithm Considered Trial and Individual Differences for Machine Learning of Human Activity Recognition”, *Journal of Advanced Computational Intelligence and Intelligent Informatics*, 21(5), 2017 (accepted).
- [4] 多田昌裕, 納谷太, 岡田昌也, 野間春生, 鳥山朋二, 小暮潔, “無線

加速度センサを用いた模範運動動作からの逸脱検出”, 人工知能学会論文誌, 23(3), pp.105-116, 2008.

- [5] 荒木雅弘, “フリーソフトでつくる音声認識システム: パターン認識・機械学習の初歩から対話システムまで”, 森北出版, 2007.
- [6] Chen, X. W., Jong, C. J., “Minimum Reference Set Based Feature Selection for Small Sample Classifications”, *The 24th International Conference on Machine Learning*, pp.153-160, 2007.